Karlsruher Institut für Technologie

DHBW
Duale Hochschule
Baden-Württemberg

# Programmieren I

## Primitive Datentypen

**Heusch 6**
**Ratz 4.3, 4.4**

Institut für Automation und angewandte Informatik

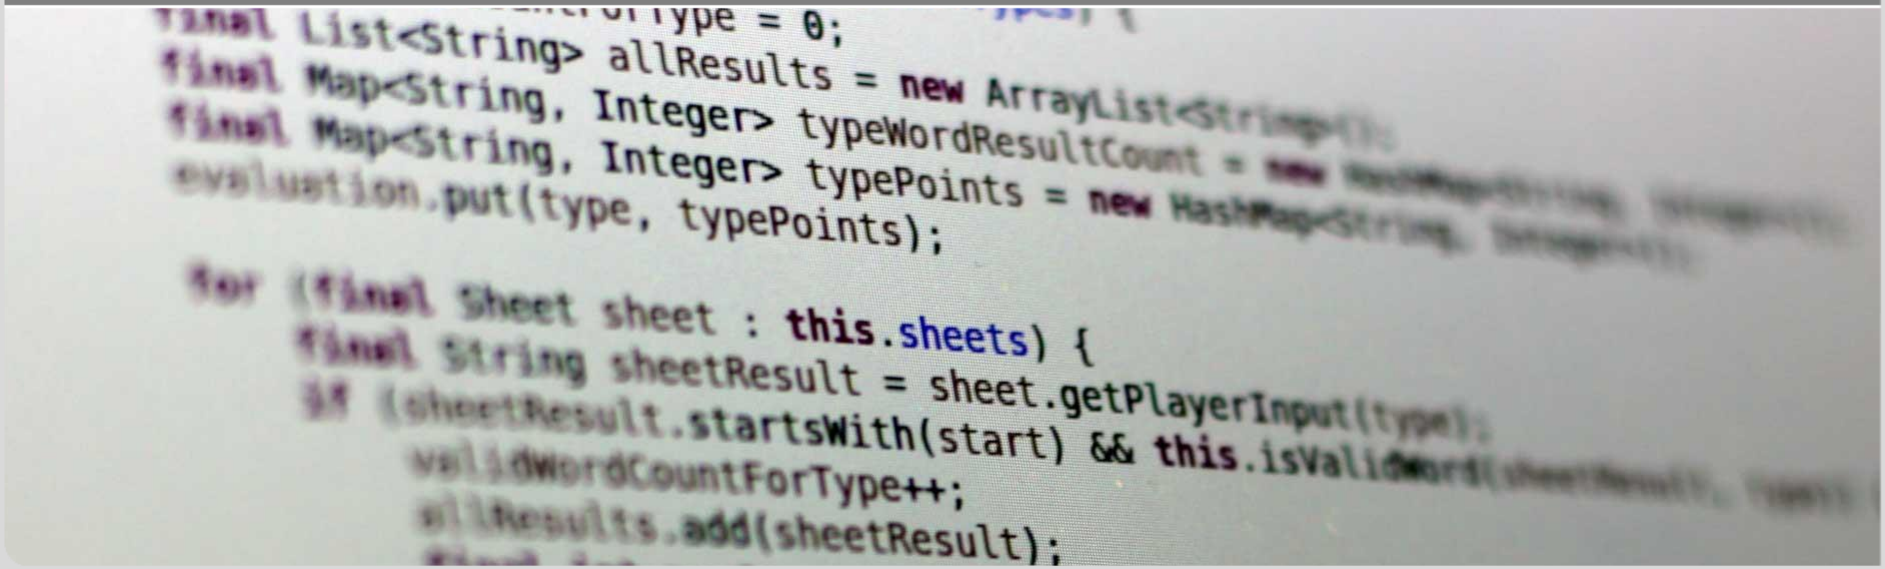

# Java-Bezeichner

- Für Variablen, Methoden, Klassen und Schnittstellen werden Bezeichner – auch *Identifizierer* (von engl. identifier) genannt – vergeben.
- Ein Bezeichner ist eine *Folge von Zeichen*, die fast beliebig lang sein kann.
  - Die Zeichen sind Elemente (Teilmenge) aus dem *gesamten Unicode-Zeichensatz*. Zulässig sind Java-Buchstaben (inkl. Zeichen wie '_', '$' und '€') und Java-Ziffern.
  - Jedes Zeichen ist für die Identifikation wichtig. Das heißt, ein Bezeichner, der 100 Zeichen lang ist, muss auch immer mit allen 100 Zeichen korrekt angegeben werden.
- Jeder Java-Bezeichner muss mit einem Unicode-Buchstaben *beginnen*. Unicode-Buchstaben sind z. B. die Buchstaben aus den Bereichen 'a' bis 'z' und 'A' bis 'Z', aber auch '_' und '$'.
- Nach dem ersten Zeichen können neben Buchstaben inkl. '_' und '$' auch Ziffern 0-9 folgen.
- Es wird zwischen *Groß- und Kleinschreibung unterschieden*.
- Leerzeichen sind innerhalb von Bezeichnern verboten.

# Beispiele für Bezeichner

- Gültige Bezeichner:
  - `mami`
  - `kulliReimtSichAufUlli`
  - `IchMussWilliAnrufen`
  - `RAPHAEL_IST_LIEB`
- Ungültige Bezeichner:
  - `2und2macht4`
  - `hose gewaschen`
  - `hurtig!`
  - `class`

# Reservierte Schlüsselwörter

```
abstract  assert  boolean  break  byte
case  catch  char  class  const*  continue
default  do  double  else enum  extends
final  finally  float  for  goto*  if
implements  import  instanceof  int
interface  long native  new  package
private  protected  public  return  short
static  strictfp  super switch
synchronized  this  throw  throws
transient  try  void  volatile  while
```

*derzeit nicht verwendet

**Heusch 5.2**
**Ratz 4.1.4**

# Konventionen für Bezeichner

| Bezeichner | Konvention | Beispiel |
|---|---|---|
| **Packages** | Kleinschreibung<br>Trennung mit Punkt („.“) | `de.dhbw.ka.prog`<br>`java.util` |
| **Klassen, Interfaces** | *UpperCamelCase*<br>*(erster Buchstabe groß)*<br>*Klassen*: <Nomen><br>*Interfaces*: <Adjektiv> | `SomeExample`<br><br>`LegalNotice`<br>`Consumable` |
| **Methoden** | lowerCamelCase<br>*(erster Buchstabe klein)*<br><Verb><Nomen> | `getInstance`<br>`performAction` |
| **Variablen** | lowerCamelCase<br>*(erster Buchstabe klein)* | `index`<br>`targetValue` |
| **Konstanten**<br>(static, final) | UPPER_SNAKE_CASE<br>(Großschreibung<br>Teilworte mit Unterstrich<br>(„_“) getrennt) | `MAX_VALUE`<br>`PI`<br>`CONF_FILE_NAME` |

# Quelltext dokumentieren

- Mit Kommentaren den Überblick bewahren
  - Kommentare erleichtern es, zu einem späteren Zeitpunkt die Funktionsweise einzelner Teile nachzuvollziehen.
  - Kommentare werden direkt in den Quelltext eingefügt.
  - Kommentare werden vom Compiler überlesen.
    Hierzu müssen sie entsprechend gekennzeichnet werden.
- In Java gibt es zwei grundlegende Kommentartypen:
  - Einzeilige Kommentare `//`
    - Kommentar bis zum Ende der Zeile.
    - Alle Zeichen hinter `//` werden vom Compiler überlesen.
  - Mehrzeilige Kommentare `/*` `*/`
    - Kommentar über mehrere Zeilen.
    - Ab der Zeichenkombination `/*` werden alle Zeichen im Quelltext vom Compiler überlesen, bis die Zeichenkombination `*/` auftritt.

# Beispiel (Kommentare)

```
class Comment {                                          // Definition der Klasse
    public static void main( String args[] ) {
      System.out.println( "Hello World" );               // Mit diesem Befehl wird
                                                         // ein Text ausgegeben
/* zu Testzwecken als Kommentar:
      System.out.println( "Hello Europa" );              // Diese Ausgabe ist als
                                                         // Kommentar gekennzeichnet
                                                         // und wird daher nicht
                                                         // ausgefuehrt
*/
   }
}
```

# Anweisungen

- Eine Anweisung (Statement) ist ein vom Programmierer erstellter Befehle zur Lösung einer Aufgabe.
- Ein Programm besteht aus eine Folge von Anweisungen, die in einer bestimmten Reihenfolge ausgeführt werden.
- Syntax für Anweisungen:
  - Eine Anweisung ist eine einfache Anweisung oder ein Anweisungsblock
  - Eine einfache Anweisung wird mit einem Semikolon abgeschlossen
  - Ein Anweisungsblock fasst mehrere Anweisungen in geschweiften Klammern `{ }` zusammen
  - Die Klammern `{ }` müssen immer paarweise auftreten
  - Anweisungsblöcke können geschachtelt werden
  - Auch leere Anweisungen (nur Semikolon) sind erlaubt

# Beispiel (Anweisung)

```
statement;                  // Einfache Anweisung

{                           // Beginn eines Anweisungsblocks
      statement1;
      statement2;
      …                     // Weitere Anweisungen
}                           // Ende des Anweisungsblocks
```

# Datentypen

- In den Anweisungen eines Programms wird mit Daten gearbeitet, die sich in ihrer Art unterscheiden:
  - Zahlen (numerische Daten)
  - Zeichen (alphanumerische Daten)
  - Boolesche (logische) Daten (Wahrheitswerte)
- Java legt mit den Datentypen fest, welche Daten jeweils zulässig sind. Sie unterscheiden sich durch:
  - ihren zulässigen Wertetyp und -bereich
  - in der Größe des dafür benötigten Speicherplatzes
- In Java gibt es zwei Arten von Datentypen:
  - Primitive Datentypen (oder einfache Datentypen)
  - Referenzdatentypen (u.a. Klassen)

# Die primitiven Datentypen

**Heusch 6**
**Ratz 4.3**

- **Numerische** Datentypen
  - Ganzzahl-Datentypen
    - Für ganze Zahlen (ohne Nachkommastellen) mit Vorzeichen.
    - Vier verschiedene Varianten: `byte`, `short`, `int`, `long`
  - Gleitkommazahl-Datentypen
    - Für gebrochene Dezimalzahlen mit Vorzeichen.
    - Zwei verschiedene Varianten: `float` und `double`
    - Nicht jede Zahl darstellbar → Rundungsfehler
- **Zeichen**-Datentyp
  - Zur Darstellung alphanumerischer Zeichen wird der Datentyp `char` verwendet.
  - Er enthält ein beliebiges UniCode-Zeichen.
- **Boolescher** (logischer) Datentyp
  - Zur Repräsentation von Wahrheitswerten wird der Datentyp **`boolean`** verwendet.
  - Werte `true` und `false` (boolesche Literale)

# Interne Darstellung von Zeichen (1)

- Es gibt zwei Gruppen von Zeichen: *druckbare Zeichen* (darstellbare Zeichen) und *Steuerzeichen*.
  - In die erste Gruppe fallen Groß- und Kleinbuchstaben, Ziffern und Sonderzeichen (!, :, +, etc.).
  - Zur zweiten Gruppe gehören z.B. der Zeilenvorschub und der horizontale Tabulator.
- Für die Speicherung und die Ein-/Ausgabe werden Zeichen als *Bitkombinationen* codiert.
  - Java verwendet den Unicode, der den ASCII-Code als Teilmenge enthält.
  - Die Bitkombination (der Code) eines Zeichen wird hier in zwei Bytes (16 Bit) *gespeichert*.
  - Die Bitkombination eines Zeichens kann auch *als Zahl aufgefasst* werden. Z.B. entspricht die Bitkombination des Buchstabens `A` die Zahl 65, des Buchstabens `a` die Zahl 97 und des Zeichens `1` der Zahl 49.

# Interne Darstellung von Zeichen (2)

Erste Zeichen des Unicode-Zeichensatzes (entspr. ASCII-Code)

| Dez. | Hex. | Zeich. | Dez. | Hex. | Zeich. | Dez. | Hex. | Zeich. | Dez. | Hex. | Zeich. |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 0000 | NUL | 32 | 0020 | | 64 | 0040 | @ | 96 | 0060 | ` |
| 1 | 0001 | SOH | 33 | 0021 | ! | 65 | 0041 | A | 97 | 0061 | a |
| 2 | 0002 | STX | 34 | 0022 | " | 66 | 0042 | B | 98 | 0062 | b |
| 3 | 0003 | ETX | 35 | 0023 | # | 67 | 0043 | C | 99 | 0063 | c |
| 4 | 0004 | EOT | ... | | | 68 | 0044 | D | 100 | 0064 | d |
| 5 | 0005 | ENQ | 45 | 002D | - | 69 | 0045 | E | 101 | 0065 | e |
| 6 | 0006 | ACK | 46 | 002E | . | ... | | | ... | | |
| 7 | 0007 | BEL | 47 | 002F | / | 87 | 0057 | W | 119 | 0077 | w |
| ... | | | 48 | 0030 | 0 | 88 | 0058 | X | 120 | 0078 | x |
| 10 | 000A | LF | 49 | 0031 | 1 | 89 | 0059 | Y | 121 | 0079 | y |
| ... | | | 50 | 0032 | 2 | 90 | 005A | Z | 122 | 007A | z |
| 12 | 000C | FF | ... | | | 91 | 005B | [ | 123 | 007B | { |
| 13 | 000D | CR | 57 | 0039 | 9 | 92 | 005C | \ | 124 | 007C | \| |
| ... | | | 58 | 003A | : | 93 | 005D | ] | 125 | 007D | } |
| 30 | 001E | RS | ... | | | 94 | 005E | ^ | 126 | 007E | ~ |
| 31 | 001F | US | 63 | 003F | ? | 95 | 005F | _ | 127 | 007F | DEL |

# Literale für primitive Datentypen (1)

- Im Quelltext verwendete Werte (z.B. Zahlen) werden als *Literale* bezeichnet
- Numerische Datentypen
  - Für numerische Werte des Integer-Datentyps können die Vorzeichen + bzw. – und die Ziffern 0..9 verwendet werden. Das Vorzeichen + kann auch entfallen.
  - Bei *Gleitkommazahlen* wird als Dezimaltrennzeichen der Punkt . verwendet.
  - Die Exponentialschreibweise für Gleitkommazahlen sieht z.B. folgendes vor: 4.56e3 4.56E3 -5.677e90 +6.777e-8
  - Für den Datentyp **`long`** wird das Suffix L verwendet, z.B. 126L
  - Für den Datentyp **`float`** wird das Suffix F (f) verwendet, z.B. 100.0F
  - Standarddatentypen: `int` (falls in `int` darstellbar) und `double`
- Boolescher Datentyp
  - Boolesche Literale sind `true` und `false`

# Literale für primitive Datentypen (2)

- Alphanumerischer Datentyp **char** für Zeichen
  - Einzelne Zeichen werden durch Apostrophe ' eingeschlossen.

```
char letter = 'X';
```

  - Zeichen können auch als Escape-Sequenzen dargestellt werden. Die Escape-Sequenz ist in Apostrophe ' zu setzen.
  - Mit der Escape Sequenz '\uhhhh' kann der Unicode für das gewünschte Zeichen direkt angegeben werden (h: Hexadezimalziffer).

| Escape-Sequenz | Bedeutung |
|---|---|
| `\uhhhh` Bsp: `\u0045` | Ein spezielles Zeichen (im Beispiel das Zeichen E mit dem hexadezimalen UniCode 0045) |
| `\b` | Backspace |
| `\t` | Tabulator |
| `\n` | line feed |
| `\f` | form feed |
| `\r` | carriage return |
| `\"` | Anführungszeichen |
| `\'` | Hochkomma |
| `\\` | Backslash |

# Liste der primitiven Datentypen in Java

| Typ | Größe | Minimum | Maximum | Defaultwert | Beispiel |
|---|---|---|---|---|---|
| `boolean` | 8 bit | - | - | `false` | `false` |
| `char` | 16 bit | Unicode 0 | Unicode $2^{16}-1$ | `\u0000` (`null`) | `'a'` |
| `byte` | 8 bit | -128 | +127 | `(byte) 0` | `34` |
| `short` | 16 bit | $-2^{15}$ | $+2^{15}-1$ | `(short) 0` | `21345` |
| `int` | 32 bit | $-2^{31}$ | $+2^{31}-1$ | `0` | `42322554` |
| `long` | 64 bit | $-2^{63}$ | $+2^{63}-1$ | `0L` | `134567L` |
| `float` | 32 bit | $2^{-149}$ | $(2-2^{-32})*2^{127}$ | `0.0f` | `3.1415f` |
| `double` | 64 bit | $2^{-1074}$ | $(2-2^{-52})*2^{1023}$ | `0.0d` | `3.253245` |
| `void` | - | - | - | | |

# Variablen (1)

- Was sind Variablen?
  - Die Anweisungen eines Programms arbeiten mit *Daten*, die *unterschiedliche Werte (variable Werte)* annehmen können, z.B. Zwischenergebnisse einer Berechnungen.
  - Hierzu werden so genannte Variablen verwendet, für die entsprechende Speicherplatz im Arbeitsspeicher des Computers reserviert wird.
  - Zugriff auf den Speicherplatz über den Variablennamen (Bezeichner).
  - Zur Deklaration von Variablen bedarf es Namen und Datentyp.

# Variablen (2)

- Voraussetzung für die Nutzung von Variablen
  - Eine Variable muss deklariert sein, bevor sie Daten aufnehmen kann.
  - Eine Variable muss einen Wert enthalten, bevor sie verwendet werden kann.

```
int a; // Variable mit Namen "a" deklariert
a = 12; // Variable "a" bekommt Wert 12
```

```
// Variable deklarieren und direkt Wert zuweisen
int b = 14;
```

# Gültigkeitsbereich lokaler Variablen

- Java kennt verschiedene Arten von Variablen.
- Variablen, die innerhalb eines Anweisungsblocks (z.B. einer Methode) deklariert werden, heißen **lokale Variablen**.
- Lokale Variablen sind  nur innerhalb des deklarierenden Blocks gültig → *lokaler Gültigkeitsbereich*.
- Eine lokale Variable verliert mit der schließenden Klammer } des Blocks ihre Gültigkeit.
- Ein Bezeichner in Java muss innerhalb seines Gültigkeits-bereichs *eindeutig* sein.
  - Innerhalb des Blocks (auch in inneren Blöcken) darf keine Variable mit gleichem Namen deklariert werden.
- Lokale Variablen primitiver Datentypen erhalten keinen Default-Wert! Hier meckert der Compiler.

**Heusch 5.2**
**Ratz 4.4**

# Beispiel für den Gültigkeitsbereich von Variablen

## Zulässig

```
{
    int number;
}
// Die Variable number
// ist hier nicht mehr
// gültig

{
    int number;
    /* jetzt existiert
     * wieder eine lokale
     * Variable mit dem
     * Namen number */
}
```

## Unzulässig

```
{
    int number;

    {
        int number;
          // unzulässig
    }
}

/* Diese Variablendeklaration
 * ist nicht zulässig, da die
 * Variable number aus dem
 * übergeordneten Block noch
 * gültig ist. */
```

# Syntax der Variablendeklaration

```
type identifier [= init_value]
        {, identifier [= init_value] };
```

**Syntax: siehe Anhang**

- Die Variablendeklaration besteht aus einem *Datentyp* (`type`) und dem *Namen* (Identifizierer, Bezeichner) der Variablen (`identifier`).
- Die Namen der Variablen werden direkt nach dem Datentyp, getrennt durch ein oder mehrere Leerzeichen, angegeben.
- Der Name der Variablen muss sich an die Vorgaben für Bezeichner halten.
- Die Deklaration einer Variablen ist eine Anweisung und wird mit einem Semikolon abgeschlossen.
- Mehrere Variablen desselben Typs können in einer Anweisung deklariert werden. Die Variablennamen werden dabei durch Kommata getrennt.
- Nach einem Zuweisungsoperator = kann der Variablen ein Anfangswert (`init_value`) zugewiesen werden (optionale Initialisierung).

# Namenskonventionen und Beispiele

- Variablennamen beginnen üblicherweise mit einem Kleinbuchstaben (*Konvention*, keine zwingende Vorgabe), z.B. `time`
- Soll ein Name aus mehreren Wörtern zusammengesetzt werden, werden die Wörter direkt hintereinander geschrieben (ohne Trennzeichen).
  Zur Abgrenzung werden die (folgenden) Wörter mit Großbuchstaben begonnen, z.B. `maxTextLength, timeToEnd`
- Gültige Beispiele:

```
float price;
double extent, radius;
int minCount = 2;
char a = 'c';
```

- Ungültige Beispiele:

```
double &count; // Bezeichner von Variablen
               // dürfen kein & enthalten
float a b c;   // mehrere Variablennamen durch Kommata trennen
```

# Werte zuweisen

- Deklaration und Initialisierung von Variablen
  - Mit der *Deklaration* einer Variablen ist durch den Datentyp lediglich festgelegt, welche Daten in der Variablen gespeichert werden können
  - Mit der Deklaration einer lokalen Variablen erfolgt keine automatische *Wertzuweisung*
    Der Wert ist noch *unbestimmt*, die Variable ist noch nicht initialisiert
  - → explizite Initialisierung (erste Wertzuweisung) möglich
- Der Wert einer Variable kann jederzeit geändert werden
  - Syntax für Wertzuweisungen an Variablen

```
identifier = expression ;
```

  - Nach dem Namen der Variablen folgt der Zuweisungsoperator = und der Ausdruck
  - Der Ausdruck kann ein Literal, oder ein komplexer Ausdruck sein
  - Die Wertzuweisung wird mit einem Semikolon abgeschlossen

# Beispiele

```
// Deklarationen
int i;
int k;
char c;
double d = 1.7; // zusätzlich zur Deklaration
                // Initialisierung

// korrekte Wertzuweisungen
i = 20;         // Leerzeichen sind erlaubt
k=i;            // ohne Leerzeichen geht es auch
c ='a';         // auch Mischen möglich

// fehlerhafte Wertzuweisungen
i = 0.15;       // 0.15 ist kein gültiger int-Wert
v = 7;          // Keine Variable mit Namen v deklariert.
c="Test";       // "Test" ist kein char-Wert
c='Test';       // 'Test' ebenfalls nicht
```

# Typkompatibilität und Typkonversion

- Typkompatibilität
  - Einer Variablen kann nur ein Wert des Datentyps zugewiesen werden, den sie selbst besitzt oder den sie aufgrund ihres Wertebereichs umfasst.
  - Beispiel: Der Datentyp **`int`** ist kompatibel zum Datentyp **`double`**, aber **`double`** ist nicht kompatibel zu **`int`**.
- Typkonversion
  - Bei kompatiblen Typen führt Java automatisch eine implizite Typkonversion durch.
  - Sind die Typen nicht kompatibel, so kann eine explizite Typkonversion (*cast*) durchgeführt werden.
  - Logische Werte (**`boolean`**) können nicht umgewandelt werden.
- Syntax für die explizite Typkonversion

```
(type) expression;
```

# Beispiele:

```
int position = 100;       // korrekt
double size = 1.45;       // korrekt
double weight = 80;       // korrekt

int number1 = 1.23;       // falsch, Fehlermeldung

int number2 = (int)1.23; // korrekt durch erzwungene
                          // Typenumwandlung

float length1 = 1.45;     // falsch, Literal ist vom Typ
                          // double. Compiler liefert:
                          // "possible loss of precision"

float length2 = 1.45F;    // korrekt
float length3 = 1.45f;    // korrekt
```

# Symbol. Konstanten – unveränderliche Variablen

- In Java werden symbolische Konstanten durch unveränderliche Variablen dargestellt.
- Sobald während der Programmausführung eine Wertzuweisung erfolgt ist, ist diese endgültig (**`final`**). Es kann keine zweite Wertzuweisung an eine Konstante erfolgen nachdem sie einen Wert erhalten hat (auch in Zuweisung möglich).
- Syntax der Deklaration und Initialisierung von symbolischen Konstanten

```
final type identifier [= init_value]
          {, identifier [= init_value] };
identifier = expression;
```

- Beispiele:

```
final double MWST = 0.19;
final double PI;
PI = 3.141592;
```

- Konvention: Üblicherweise werden Konstanten mit Großbuchstaben geschrieben.

# Zeichenketten

- Für Zeichenketten (Strings) gibt es keinen primitiven Datentyp.
- Für Zeichenketten gibt es in Java die Klasse String.
- Diese Klasse wird später ausführlich behandelt.
- Da in den folgenden Beispielen zuweilen aber Strings verwendet werden, vorab schon ein paar Informationen
  - String-Literale (Zeichenketten im Quellprogramm) werden in doppelte Anführungszeichen " gesetzt, z.B. "Test".
  - Eine Zeichenkette kann mit + an eine andere Zeichenkette angehängt werden (Stringverkettung, Konkatenation). Beispiel: `"Hal" + "lo"`
  - Zeichenketten besteht aus Unicode-Zeichen.

# Anhang: Beschreibung der Syntax von JAVA

## Bei Sprachen unterscheidet man Syntax und Semantik:

- **Syntax**: Legt fest, welche Ausdrücke *erlaubt* sind (sprachliche Form).
  - Deutsch: „Der Baum blüht.“ und „Der Baum spaziert.“ sind syntaktisch korrekte Sätze.
  - *Beispiel* aus Java: Nach dem Wort `class` folgt ein Wort und anschließend eine in geschweifte Klammern eingeschlossene Zeichenfolge.
- **Semantik**: Legt die *Bedeutung* eines Ausdrucks der Sprache fest.
  - Deutsch: Die beiden Sätze oben haben unterschiedliche (mehr oder weniger sinnvolle) Bedeutungen.
  - Beispiel aus Java: Das Schlüsselwort `class` leitet eine Klassendefinition ein. Das Wort direkt nach `class` ist der Name der Klasse.

# Formale Sprachen

- Programmiersprachen sind **formale Sprachen**.
- Für *formale* Sprachen ist die Syntax exakt definiert. Es ist festgelegt:
  - Zulässige *Zeichen* der Sprache
  - Zulässige Ausdrücke (*Wörter*, Zeichenketten aus den Zeichen der Sprache)
- Beispiel:

  Gegeben sei das Alphabet (die Menge von Zeichen)  A = {"a", "b", "c"}.

  Die **Sprache $L_1$** sei die Menge aller Wörter über A, die mit "a" beginnen und mit "a" enden.

  Dann sind folgende Zeichenketten Wörter von $L_1$:

  "a", "aa", "aaa", "aba", "aca", "aaaa", "aaba", "aaca", ...

  Keine Wörter von $L_1$ sind dagegen:

  "", "b", "c", "ab", "ca", "bcc", ...

# Grammatik (1)

- Die meisten Sprachen haben *unendlich viele* Wörter (potentielle Zeichenketten), so dass man durch Aufzählung der Wörter die Sprache nicht definieren kann.
- Eine **Grammatik** im Sinne der Informatik ist eine allgemeine, eindeutige Beschreibung einer *formalen* Sprache mit Hilfe von *Regeln*.
- Sinn und Zweck einer Grammatik: Sie soll eine *endliche Beschreibung* einer Sprache ermöglichen.
  (Vgl. Vorlesung „Theoretische Informatik“)

# Grammatik (2)

Eine Grammatik G = (T,N,P,S) besteht aus 4 Teilen:

T Die Menge der *Terminalsymbole*. Aus diesen werden die Wörter der Sprache gebildet.
Terminalsymbole sind Zeichen des zugrunde liegenden Alphabets.

N Die Menge der *Nichtterminalsymbole* (Hilfssymbole/Variablen für syntaktische Einheiten).
Sie treten in der Sprache nicht auf, sondern müssen durch Terminalsymbole ersetzt werden.

P Die Menge der *Produktionen* (auch Produktionsregeln oder Regeln genannt).

Eine Regel X → Y besagt, dass ein Teilwort X durch ein Teilwort Y ersetzt werden kann, wobei X und Y aus Terminal- und Nichtterminalsymbolen bestehen.

S Das *Startsymbol* (ein spezielles Element aus N), von dem ausgehend die Produktionen angewandt werden.

# Kontextfreie Grammatiken

- Im Allgemeinen können linke und rechte Seite von Produktionen aus beliebigen Kombinationen von Terminal- und Nichtterminalsymbolen bestehen.
- Die für die Informatik wichtigste Kategorie von Grammatiken sind diejenigen,
  deren Produktionen auf der linken Seite aus *genau einem Nichtterminalsymbol* bestehen.
- Diese Grammatiken heißen *kontextfrei*.

# Backus-Naur-Form (BNF)

- Die Backus-Naur-Form (BNF) ist eine häufig verwendete *Beschreibungsform für* kontextfreie *Grammatiken*.
- Die BNF wird insbesondere zur Beschreibung der Syntax von *Programmiersprachen* verwendet.
- Die linke Seite jeder Regel besteht aus *einem* Nichtterminalsymbol.
- Die rechte Seite einer Regel besteht aus einer beliebig langen Kette, die Terminal- und Nichtterminalsymbole enthalten kann.
  - Die „leere“ rechte Seite ($\lambda$) ist erlaubt.
- Linke und rechte Seite einer Regel werden durch das Zeichen „::=“ voneinander getrennt.
- Schreibweise in dieser Vorlesung:
  - Terminalsymbole sind **fett** gedruckt.
  - Nichtterminalsymbole sind *kursiv* gedruckt.
  - Symbole der Metasprache BNF sind in Standard-Schrift gedruckt.

# Beispiel – Grammatik für $L_1$ in BNF

T = { **a**, **b**, **c** }

N = { *Wort*, *Buchstabe*, *Teilwort* }

P = {

| | | | |
|---|---|---|---|
| *Wort* | ::= | **a** *Teilwort* **a** | (1) |
| *Wort* | ::= | **a** | (2) |
| *Teilwort* | ::= | *Buchstabe* *Teilwort* | (3) |
| *Teilwort* | ::= | $\lambda$ | (4) |
| *Buchstabe* | ::= | **a** | (5) |
| *Buchstabe* | ::= | **b** | (6) |
| *Buchstabe* | ::= | **c** | (7) |

}

S = *Wort*

# Erweiterte Backus-Naur-Form (EBNF)

- Weil BNF-Grammatiken unübersichtlich werden können, wurde die BNF um einige *Abkürzungsmöglichkeiten* erweitert.
- Dies führt zur Erweiterten Backus-Naur-Form (EBNF).

- Es gibt verschiedene Varianten der EBNF.
- Eine gebräuchliche sieht folgende Abkürzungsmöglichkeiten vor:

| | |
|---|---|
| \| | der senkrechte Strich trennt Alternativen |
| [ ] | eckige Klammern enthalten optionale Bestandteile |
| { } | geschweifte Klammern enthalten Bestandteile, die null, ein oder mehrfach wiederholt werden dürfen |
| { }+ | geschweifte Klammern mit + enthalten Elemente, die ein oder mehrfach wiederholt werden können |
| ( ) | runde Klammern gruppieren mehrere Bestandteile, z.B. mehrere Alternativen |

# Beispiel: Grammatik für $L_1$ in EBNF

T = { **a**, **b**, **c** }

N = { *Wort*, *Buchstabe*, *Teilwort* }

P = { *Wort* ::= **a** *Teilwort* **a** | **a** (1+2)

*Teilwort* ::= *Buchstabe Teilwort* | $\lambda$ (3+4)

*Buchstabe* ::= **a** | **b** | **c** (5-7)

}

S = *Wort*

# Sprache – ein zweites Beispiel (1)

- Gegeben sei das Alphabet

  A = {"1", "2", "3", "4", "5", "6", "7", "8", "9", "0", "+", "-", "*", "/", "(", ")"}

- Die Menge $L_A$ der *arithmetischen Ausdrücke* ist eine Sprache über A.

  Z.B. gehören folgenden Wörter zu $L_A$:

  122+4

  8*(4+177/3-(11*(18+7)))

  13

  Die folgenden Wörter gehören nicht zu $L_A$:

  28(18

  ++/-5

# Sprache – ein zweites Beispiel (2)

- EBNF-Grammatik für die Sprache $L_A$ (einfache arithmetische Ausdrücke):

T = { **1**, **2**, **3**, **4**, **5**, **6**, **7**, **8**, **9**, **0**, **+**, **-**, *****, **/**, **(**, **)** }

N = { *Ausdruck*, *Term*, *Faktor*, *Zahl*, *Ziffer* }

P = {
*Ausdruck* ::= *Term* { ( **+** | **-** ) *Term* } (1)
*Term* ::= *Faktor* { ( ***** | **/** ) *Faktor* } (2)
*Faktor* ::= *Zahl* | **(** *Ausdruck* **)** (3)
*Zahl* ::= {*Ziffer*}+ (4)
*Ziffer* ::= **0** | **1** | **2** | **3** | **4** | **5** | **6** | **7** | **8** | **9** (5)
}

S = *Ausdruck*